

# Kernel Pwn Cheat Sheet

- [Kernel version](#)
- [Kernel config](#)
- [Process management](#)
  - [task\\_struct](#)
  - [current](#)
- [Syscall](#)
- [Memory allocator](#)
  - [kmem\\_cache](#)
  - [kmem\\_cache\\_create](#)
  - [kmalloc](#)
  - [kfree](#)
- [Physemem](#)
- [Paging](#)
- [Copy from/to user](#)
- [Symbol](#)
- [Snippet](#)
- [Structures](#)
  - [ldt\\_struct](#)
  - [shm\\_file\\_data](#)
  - [seq\\_operations](#)
  - [msg\\_msg, msg\\_msgseg](#)
  - [subprocess\\_info](#)
  - [timerfd\\_ctx](#)
  - [pipe\\_buffer](#)
  - [tty\\_struct](#)
  - [setxattr](#)
  - [sk\\_buff](#)
- [Variables](#)
  - [modprobe\\_path](#)
  - [core\\_pattern](#)
  - [poweroff\\_cmd](#)
  - [n\\_tty\\_ops](#)

## Kernel version

```
commit 09688c0166e76ce2fb85e86b9d99be8b0084cdf9 (HEAD -> master, tag: v5.17-rc8,
origin/master, origin/HEAD)
Author: Linus Torvalds <torvalds@linux-foundation.org>
Date:   Sun Mar 13 13:23:37 2022 -0700
```

Linux 5.17-rc8

## Kernel config

config	memo
CONFIG_KALLSYMS	/proc/sys/kernel/kptr_restrict

CONFIG_USERFAULTFD	/proc/sys/vm/unprivileged_userfaultfd
CONFIG_STATIC_USERMODEHELPER	
CONFIG_SLUB	default allocator
CONFIG_SLAB	
CONFIG_SLAB_FREELIST_RANDOM	
CONFIG_SLAB_FREELIST_HARDENED	
CONFIG_FG_KASLR	
CONFIG_BPF	/proc/sys/kernel/unprivileged_bpf_disabled
CONFIG_SMP	multi-processor
CONFIG_HAVE_STACKPROTECTOR	cannary
CONFIG_RANDOMIZE_BASE	kaslr
CONFIG_HARDENED_USERCOPY	prohibit copying outside a specific region within an object

## Process management

### task\_struct

- [task\\_struct](#)
  - [thread info](#)
    - syscall\_work
  - [cred](#)
  - tasks
    - [init task](#)
      - [init cred](#)
  - comm
    - prctl(PR\_SET\_NAME, name);
  - [thread\\_struct](#)
- [start kernel](#)
  - [cred init](#)
  - [fork init](#)
    - [task\\_struct whitelist](#)
      - [arch thread struct whitelist](#)
      - [fpu thread struct whitelist](#)

### current

- [current](#)
  - [get\\_current](#)
    - [current task](#)
      - [DECLARE\\_PER\\_CPU](#)
        - [DECLARE\\_PER\\_CPU\\_SECTION](#)

- [PCPU\\_ATTRS](#)
      - *case CONFIG\_SMP*
        - [PER\\_CPU\\_BASE\\_SECTION](#)
  - [this\\_cpu\\_read\\_stable](#)
    - [\\_\\_pcpu\\_size\\_call\\_return](#)
      - [this\\_cpu\\_read\\_stable\\_8](#)
        - [percpu\\_stable\\_op](#)
          - *case CONFIG\_SMP*
            - `movq %%gs:%P[var], %[val]` where  
var = &current\_task
- [start\\_kernel](#)
  - [setup\\_per\\_cpu\\_areas](#)
    - *case CONFIG\_SMP*
      - [per\\_cpu\\_offset](#)
      - `__per_cpu_offset[cpu] = pcpu_base_addr - __per_cpu_start + pcpu_unit_offsets[cpu]`
  - [switch to new gdt](#)
    - [load\\_percpu\\_segment](#)
      - [cpu kernelmode gs\\_base](#)
        - [fixed\\_percpu\\_data](#)
          - [DECLARE PER CPU FIRST](#)
          - [fixed\\_percpu\\_data](#)
      - [per\\_cpu](#)
        - *case CONFIG\_SMP*
          - [per\\_cpu\\_ptr](#)
            - [SHIFT PERCPU\\_PTR](#)
            - [RELOC\\_HIDE](#)
  - *case CONFIG\_SMP*
    - `gs = &fixed_percpu_data.gs_base + __per_cpu_offset[cpu]`

## Syscall

- [entry SYSCALL 64](#)
  - [pt\\_regs](#)
    - `pt_regs` may be use for stack pivoting
  - [do\\_syscall 64](#)
    - `add_random_kstack_offset();`
    - [syscall enter from user mode](#)
      - [\\_\\_syscall enter from user work](#)
        - [syscall trace enter](#)
          - `SYSCALL_WORK_SECCOMP`

- [do\\_syscall\\_x64](#)
- [swaps\\_restore\\_regs\\_and\\_return\\_to\\_usermode](#)

## Memory allocator

### kmem\_cache

- *case CONFIG\_SLUB*
  - [kmem\\_cache](#)
    - [kmem\\_cache\\_cpu](#)
      - freelist
    - [slab](#)
      - slab\_cache
      - freelist
  - offset
  - random
  - [kmem\\_cache\\_node](#)
- *case CONFIG\_SLAB*
  - [kmem\\_cache](#)
    - [array\\_cache](#)
      - entry
    - [kmem\\_cache\\_node](#)
      - shared

### kmem\_cache\_create

- [kmem\\_cache\\_create](#)
  - useroffset = 0
  - usersize = 0
  - [kmem\\_cache\\_create\\_usercopy](#)
    - [create\\_cache](#)
      - *case CONFIG\_SLUB*
        - [\\_kmem\\_cache\\_create](#)
          - [kmem\\_cache\\_open](#)
            - [calculate\\_order](#)
            - [calculate\\_sizes](#)
              - [\\_\\_make](#)
                - [order\\_objects](#)
    - *case CONFIG\_SLAB*
      - [\\_kmem\\_cache\\_create](#)
        - [set\\_objfreelist\\_slab\\_cache](#)
          - [calculate\\_slab\\_order](#)
- [start\\_kernel](#)
  - [mm\\_init](#)
    - [kmem\\_cache\\_init](#)

- `useroffset = 0`
- `usersize = kmalloc_info[INDEX_NODE].size`
- [create\\_kmalloc\\_cache](#)
  - [create\\_boot\\_cache](#)
    - `__kmem_cache_create`

## kmalloc

- [kmalloc](#)
  - [kmalloc\\_index](#)
    - [\\_\\_kmalloc\\_index](#)
      - `case CONFIG_SLUB`
        - `#define KMALLOC_MIN_SIZE 8`
      - `case CONFIG_SLAB`
        - `#define KMALLOC_MIN_SIZE 32`
  - [kmalloc\\_caches](#)
  - [kmalloc\\_type](#)
    - `#define GFP_KERNEL_ACCOUNT (GFP_KERNEL | __GFP_ACCOUNT)`
    - `GFP_KERNEL → KMALLOC_NORMAL`
    - `GFP_KERNEL_ACCOUNT → KMALLOC_CGROUP`
  - `case CONFIG_SLUB`
    - [kmem\\_cache\\_alloc\\_trace](#)
      - [slab\\_alloc](#)
        - [slab\\_alloc\\_node](#)
          - [\\_\\_slab\\_alloc](#)
            - [\\_\\_slab\\_alloc](#)
              - `slab = c->slab = slub_percpu_partial(c);`
              - [new\\_slab](#)
                - [allocate\\_slab](#)
                  - [alloc\\_slab\\_page](#)
                  - [shuffle\\_freelist](#)
        - [get\\_freepointer\\_safe](#)
          - [freelist\\_ptr](#)
            - [swab](#)
              - [\\_\\_swab](#)
                - [\\_\\_swab64](#)
                  - [\\_\\_constant\\_swab64](#)
    - `case CONFIG_SLAB`
      - [kmem\\_cache\\_alloc\\_trace](#)
        - [slab\\_alloc](#)
          - [\\_\\_do\\_cache\\_alloc](#)
            - [\\_\\_cache\\_alloc](#)
              - [cache\\_alloc\\_refill](#)

- [\\_\\_cache\\_alloc\\_node](#)
  - [cache\\_grow\\_begin](#)
    - [kmem\\_getpages](#)
      - [\\_\\_alloc\\_pages\\_node](#)
  - [cache\\_init\\_objs](#)
    - [shuffle\\_freelist](#)

## kfree

- case CONFIG\_SLUB
  - [kfree](#)
    - [virt\\_to\\_folio](#)
      - [virt\\_to\\_page](#)
        - [\\_\\_pa](#)
          - [\\_\\_phys\\_addr](#)
            - [\\_\\_phys\\_addr\\_nodebug](#)
              - `x - __START_KERNEL_map +  
__START_KERNEL_map - PAGE_OFFSET`
              - `#define __PAGE_OFFSET  
page_offset_base`
      - [pfn\\_to\\_page](#)
        - [\\_\\_pfn\\_to\\_page](#)
          - [vmemmap](#)
            - [VMEMMAP\\_START](#)
              - `vmemmap_base`
      - [page\\_folio](#)
        - [compound\\_head](#)
          - [pageflags](#)
      - [folio\\_slab](#)
      - [slab\\_free](#)
        - [do\\_slab\\_free](#)
          - `likely(slab == c->slab) → likely(slab == slab->slab_cache->cpu_slab->slab)`
          - [set\\_freepointer](#)
            - `BUG_ON(object == fp);`
          - [slab\\_free](#)
            - `put_cpu_partial(s, slab, 1);`
  - case CONFIG\_SLAB
    - [kfree](#)
      - [\\_\\_cache\\_free](#)
        - [cache\\_flusharray](#)
        - [\\_\\_free\\_one](#)

- `WARN_ON_ONCE(ac->avail > 0 && ac->entry[ac->avail - 1] == objp)`

## Physem

- [page tables](#)
  - `page_offset_base`
    - heap base address (by `kmalloc`) and it is mapped to `/dev/mem`
    - `secondary_startup_64` can be found at `page_offset_base + offset`
  - `vmalloc_base`
  - `vmemmap_base`
    - base address of [pages](#)

## Paging

- CR3, Page Global Directory, Page Upper Directory, Page Middle Directory, Page Table Entry are used
- each register or variable holds an encoded pointer, not a raw pointer
- the 12~51 bits of each register or variable indicates the base address of the next directory
- see [5.3.3 4-Kbyte Page Translation / AMD64 Architecture Programmer's Manual, Volume 2](#) for details
- last byte of Page Global Directory(PML4E) often be 0x67(0b01100111)

## Copy from/to user

- [copy from user](#)
  - [check copy size](#)
    - `case CONFIG_HARDENED_USERCOPY`
      - [check object size](#)
        - [\\_\\_check object size](#)
          - [check heap object](#)
            - `case CONFIG_HARDENED_USERCOPY`
              - `case CONFIG_SLUB`
                - [\\_\\_check heap object](#)
              - `case CONFIG_SLAB`
                - [\\_\\_check heap object](#)
            - `otherwise`
              - [\\_\\_check heap object](#)
          - [check page span](#)
    - `otherwise`
      - [check object size](#)
- [copy to user](#)

## Symbol

- [EXPORT\\_SYMBOL](#)

- [EXPORT\\_SYMBOL](#)
    - [EXPORT\\_SYMBOL](#)
      - [\\_\\_cond\\_export\\_sym](#)
        - [\\_\\_cond\\_export\\_sym](#)
          - [\\_\\_cond\\_export\\_sym\\_1](#)
            - [EXPORT\\_SYMBOL](#)
              - [\\_\\_KSYMTAB\\_ENTRY](#)
                - [RO\\_DATA](#)
- [kernel\\_symbol\\_value](#)
  - [offset\\_to\\_ptr](#)

## Snippet

- gain root privileges
  - (kernel) `commit_creds(prepare_kernel_cred(NULL));`
- break out of namespaces
  - (kernel) `switch_task_namespaces(find_task_by_vpid(1), init_nsproxy);`
  - (user) `setns(open("/proc/1/ns/mnt", O_RDONLY), 0);`
  - (user) `setns(open("/proc/1/ns/pid", O_RDONLY), 0);`
  - (user) `setns(open("/proc/1/ns/net", O_RDONLY), 0);`

## Structures

| structure       | size          | flag (v5.14+)      | memo                    |
|-----------------|---------------|--------------------|-------------------------|
| ldt_struct      | 16            | GFP_KERNEL_ACCOUNT |                         |
| shm_file_data   | 32            | GFP_KERNEL         |                         |
| seq_operations  | 32            | GFP_KERNEL_ACCOUNT | /proc/self/stat         |
| msg_msg         | 48 ~ 4096     | GFP_KERNEL_ACCOUNT |                         |
| msg_msgseg      | 8 ~ 4096      | GFP_KERNEL_ACCOUNT |                         |
| subprocess_info | 96            | GFP_KERNEL         | socket(22, AF_INET, 0); |
| timerfd_ctx     | 216           | GFP_KERNEL         |                         |
| pipe_buffer     | 640 = 40 x 16 | GFP_KERNEL_ACCOUNT |                         |
| tty_struct      | 696           | GFP_KERNEL         | /dev/ptmx               |
| setxattr        | 0 ~           | GFP_KERNEL         |                         |
| sk_buff         | 320 ~         | GFP_KERNEL_ACCOUNT |                         |

### [ldt\\_struct](#)

- [modify\\_ldt](#)
  - [write\\_ldt](#)
    - `#define LDT_ENTRIES 8192`



- `#define LDT_ENTRY_SIZE 8`
- [alloc\\_ldt\\_struct](#)
- [read\\_ldt](#)
  - [desc\\_struct](#)
  - `copy_to_user`
    - `copy_to_user` won't panic the kernel when accessing wrong address

## shm\_file\_data

- [shmat](#)
  - [do\\_shmat](#)

## seq\_operations

- [proc\\_stat\\_init](#)
  - [stat\\_proc\\_ops](#)
- [stat\\_open](#)
  - [single\\_open\\_size](#)
    - [single\\_open](#)
- [seq\\_read\\_iter](#)
  - `m->op->start`

## msg\_msg, msg\_msgseg

- [msg\\_queue](#)
  - `q_messages` → `msg_msg`
- [msgsnd](#)
  - [ksys\\_msgsnd](#)
    - [do\\_msgsnd](#)
      - [load\\_msg](#)
      - [alloc\\_msg](#)
- [msgrcv](#)
  - [ksys\\_msgrcv](#)
    - [do\\_msgrcv](#)
      - `#define MSG_COPY 040000`
      - [copy\\_msg](#)

## subprocess\_info

- [socket](#)
  - [\\_\\_sys\\_socket](#)
    - [sock\\_create](#)
      - [\\_\\_sock\\_create](#)
        - [\\_\\_request\\_module](#)
          - [call\\_modprobe](#)
            - [call\\_usermodehelper\\_setup](#)

## timerfd\_ctx

- [timerfd\\_create](#)
- [timerfd\\_release](#)
  - `kfree_rcu`

## pipe\_buffer

- [pipe](#), [pipe2](#)
  - [do\\_pipe2](#)
    - [do\\_pipe\\_flags](#)
      - [create\\_pipe\\_files](#)
      - [get\\_pipe\\_inode](#)
      - [alloc\\_pipe\\_info](#)
        - `#define PIPE_DEF_BUFFERS 16`
    - [pipefifo\\_fops](#)
- [pipe\\_write](#)
  - `buf->ops = &anon_pipe_buf_ops;`
- [pipe\\_release](#)
  - [put\\_pipe\\_info](#)
    - [free\\_pipe\\_info](#)
    - [pipe\\_buf\\_release](#)
      - `ops->release`

## tty\_struct

- [unix98\\_pty\\_init](#)
  - [tty\\_default\\_fops](#)
    - [tty\\_fops](#)
- [ptmx\\_open](#)
  - [tty\\_init\\_dev](#)
    - [alloc\\_tty\\_struct](#)
- [tty\\_ioctl](#)
  - [tty\\_paranoia\\_check](#)
    - `#define TTY_MAGIC 0x5401`
  - [tty\\_pair\\_get\\_tty](#)
  - `tty->ops->ioctl`

## **setxattr**

- [setxattr](#)
  - [path\\_setxattr](#)
    - [setxattr](#)
      - `vfs_setxattr` may fail, but `kvmalloc` and `kvmfree` complete successfully

## sk\_buff

- [socketpair](#)
  - [\\_\\_sys\\_socketpair](#)
    - [sock\\_create](#)
      - [\\_\\_sock\\_create](#)
        - *case PF\_UNIX*
          - [unix\\_family\\_ops](#)
            - [unix\\_create](#)
              - *case SOCK\_DGRAM*
                - [unix\\_dgram\\_ops](#)
              - [unix\\_create1](#)
                - `sk->sk_allocation = GFP_KERNEL_ACCOUNT;`
- [unix\\_dgram\\_sendmsg](#)
  - [sock\\_alloc\\_send\\_skb](#)
    - [alloc\\_skb\\_with\\_frags](#)
    - [alloc\\_skb](#)
      - [\\_\\_alloc\\_skb](#)
        - `struct skb_shared_info` is at the end of `data`

## Variables

| variable      | memo                          |
|---------------|-------------------------------|
| modprobe_path | /proc/sys/kernel/modprobe     |
| core_pattern  | /proc/sys/kernel/core_pattern |
| poweroff_cmd  |                               |
| n_tty_ops     | (read) scanf, (ioctl) fgets   |

### [modprobe\\_path](#)

- [execve](#)
  - [do\\_execve](#)
    - [do\\_execveat common](#)
      - [bprm\\_execve](#)
        - [exec\\_binprm](#)
          - [search\\_binary\\_handler](#)
            - [\\_\\_request\\_module](#)
              - [call\\_modprobe](#)
                - [call\\_usermodehelper\\_setup](#)
                - [call\\_usermodehelper\\_exec](#)

### [core\\_pattern](#)

- [do\\_coredump](#)
  - [format\\_corename](#)
  - [call\\_usermodehelper\\_setup](#)
  - [call\\_usermodehelper\\_exec](#)

## **[poweroff\\_cmd](#)**

- [orderly\\_poweroff](#)
  - [poweroff\\_work\\_func](#)
    - [\\_\\_orderly\\_poweroff](#)
      - [run\\_cmd](#)
        - [call\\_usermodehelper](#)
          - [call\\_usermodehelper\\_setup](#)
          - [call\\_usermodehelper\\_exec](#)

## **[n\\_tty\\_ops](#)**

- [tty\\_struct](#)
  - [tty\\_ldisc](#)
- [n\\_tty\\_init](#)
  - [tty\\_register\\_ldisc](#)